

ESTUDO DE ALGORITMOS DE APRENDIZADO DE MÁQUINA PARA A PREDIÇÃO DA DOENÇA DE ALZHEIMER POR MEIO DA FALA

Julio Cesar Riveros Cardus^{(1)*}, Willian Zalewski⁽²⁾

⁽¹⁾ Voluntário, Biotecnologia, Instituto Latino-Americano de Ciências da Vida e da Natureza (ILACVN), UNILA.

⁽²⁾ Orientador, Instituto Latino-Americano de Tecnologia, Infraestrutura e Território (ILATIT), UNILA.

*E-mail de contato: jcr.cardus.2020@aluno.unila.edu.br

1. RESUMO

A demência (DA) se manifesta como uma doença neurodegenerativa, com impactos nos âmbitos cognitivo, psicológico e comportamental, situando-se, atualmente, como a sétima principal causa de óbitos. No contexto do Sistema Único de Saúde do Brasil, a despesa destinada a internações e serviços hospitalares em 2018 alcançou a cifra de R\$28.381.990,28 [1]. O diagnóstico atual para avaliar a progressão da DA está ancorado na realização de imagens cerebrais ou testes cognitivos, avaliações que frequentemente se traduzem em custos elevados ou em avaliações médicas extensas. Como a demência é incurável, a prevenção é a melhor estratégia para retardar seu aparecimento e progressão. Um dos aspectos da predição de doenças que tem conquistado a atenção dos pesquisadores é a detecção de DA por meio de métodos de Inteligência Artificial, em especial, técnicas de Aprendizado de Máquina (ML). Inúmeras soluções automatizadas de diagnóstico, para a previsão precoce de demência têm sido propostas na literatura, principalmente valendo-se de conjuntos de dados de neuroimagem. Recentemente, a análise da voz tem emergido como um método de triagem acessível e não invasivo, com potencial para identificar deterioração cognitiva nos estágios iniciais da DA. Nosso escopo englobou a avaliação de técnicas de ML e de séries temporais, com o intuito de diferenciar entre pacientes acometidos por demência e indivíduos saudáveis usando dados de voz. O conjunto de dados empregado neste estudo origina-se do Pitt Corpus, uma compilação de gravações de fala contendo descrições de imagens, fornecidas tanto por indivíduos com funcionamento cognitivo regular quanto por pacientes diagnosticados com DA. O banco de dados Pitt inclui gravações de fala de 243 indivíduos do grupo de controle e 306 indivíduos diagnosticados com DA. Neste estudo, a partir das gravações obtidas, os dados de áudio brutos passaram por uma etapa de segmentação utilizando a ferramenta TRESTLE [2], visando a separação das vozes dos pacientes dos intermediários que conduziam o teste. Posteriormente, esses dados foram transformados em representações numéricas, por intermédio da biblioteca de processamento de áudio, *librosa* [3], nesse contexto, foi adotada uma taxa de amostragem de 16 Hz. A **Figura 1** apresenta uma comparação dos espectros de voz entre pacientes controle e pacientes com demência. Cada linha no gráfico representa o espectro de voz de um indivíduo. Os resultados dessa etapa foram empregados como entrada para os modelos de ML disponíveis na linguagem de programação *Python* 3. Entre os algoritmos submetidos a análise, o *KNeighborsTimeSeriesClassifier*, *TimeSeriesSVC* e *LearningShapelets*, revelaram acurácias médias de 57,21%, 54,64% e 55,74% respectivamente. No entanto, os resultados obtidos não refletem uma distinção efetiva entre as classes, uma vez que uma acurácia em torno de 55% pode ser associada a um algoritmo que, de forma simplista, agrupa todos os casos na classe majoritária. Algoritmos baseados em arquiteturas de redes neurais, como

InceptionTimePlus, *XceptionTime* e *ResNet*, enfrentaram dificuldades em alcançar uma performance significativa, obtendo uma acurácia média de apenas 44.93%. Os resultados obtidos fornecem uma visão das dificuldades que cercam a previsão da DA. Uma das hipóteses para explicar os resultados encontrados é a possibilidade de que a representação temporal não seja capaz de traduzir adequadamente a complexidade subjacente dos dados. Nesse sentido, como perspectiva para trabalhos futuros, planeja-se explorar outros domínios de representação dos dados, como o domínio de frequências, com o objetivo de ampliar a compreensão do problema e aprimorar os resultados.




Figura 1. Comparação de Espectros entre Pacientes de Controle e Demência.

2. REFERÊNCIAS

1. ZALLI, M.; FARAH, H.O.; ANTUNES, M.D. **Epidemiological aspects and health costs due dementia in Brazil.** Rev Med (São Paulo), v. 99, n. 6, p. 563-7, 2020.
2. LI, C. et al. **TRESTLE: Toolkit for Reproducible Execution of Speech, Text and Language Experiments.** AMIA Summits on Translational Science Proceedings, v. 2023, p. 360, 2023.
3. MCFEE, B. et al. **librosa: Audio and music signal analysis in python.** In: Proceedings of the 14th python in science conference. 2015. p. 18-25.